

Adarsh Sarda

KI-SICHERHEITSFORSCHER / M.SC.-STUDENT

Amberg, Deutschland
+49 1551 0438756 · adarshsarda29@gmail.com
adarshsarda.github.io · linkedin.com/in/adarshsarda
Geboren 29.05.2000 in Indien · Verfügbar: Werkstudent, 20 Std./Woche

Über mich

M.Sc.-Student der Künstlichen Intelligenz an der OTH Amberg-Weiden mit Schwerpunkt KI-Sicherheit, Red-Teaming von LLMs und Adversarial Machine Learning. Mir ist eine belastbare, ehrlich berichtete Evaluierung wichtig — Nenner, Kontrollen und Konfidenzintervalle statt Adjektive.

Bildungsweg

03/2025 heute	M.Sc. Künstliche Intelligenz für industrielle Anwendungen OTH Amberg-Weiden, Bayern · Note 2,0
08/2019 06/2023	B.Tech in Information Technology Institute of Engineering and Management, Kalkutta · Note 1,7 (8,6/10)

Berufserfahrung

01/2023 10/2024	Research Analyst — GreyB Research, Chandigarh, Indien – Entwickelte ein ML-System zur automatisierten Technologieklassifikation umfangreicher Patentkorpora. – Führt Infringement-, Prior-Art- und Tech-Scouting-Analysen in KI/ML, Blockchain, 3GPP und IETF für internationale Kunden durch.
--------------------	---

Ausgewählte Arbeiten

Ordnungsabhängige semantische Backdoors (ODSB) — Multi-Turn-LLMs
100% In-Distribution-ASR (n=140), 0% False-Trigger-Rate, 0,887 auf ungesesehenen Paraphrasen; Qwen2.5-3B + LoRA, präregistriert. Code + Bericht öffentlich.

Red Teaming AI Systems: A Practitioner's Guide
Sechsstufige Methodik für Chatbots, RAG und Agenten, abgebildet auf NIST AI RMF, OWASP und MITRE ATLAS.

Multimodale Emotionserkennung — Springer-Buchkapitel (2023)
Co-Autor eines LSTM-Modells aus Sprache + Text mit ca. 86% Genauigkeit.

Kenntnisse

Tools Python, PyTorch, scikit-learn, Vertex AI (GCP)

KI LLMs & NLP, Adversarial ML, Explainable AI, Threat Modelling, LLM-Red-Teaming, Prompt Engineering

Sprachen Englisch C1, Deutsch B1, Hindi (Muttersprache)

Interessen

Musik (Gesang, Synthesizer, Ukulele, Gitarre) · Kochen (asiatische Küche, besonders indische)