

Adarsh Sarda

KI-SICHERHEITSFORSCHER / M.SC.-STUDENT

Amberg, Deutschland | +49 1551 0438756
adarshsarda29@gmail.com | adarshsarda.github.io
linkedin.com/in/adarshsarda | github.com/adarshsarda



PERSÖNLICHE DATEN

WOHNORT

Amberg, Deutschland

GEBOREN

29.05.2000 in Indien

VERFÜGBARKEIT

Werkstudent, 20 Std./Woche, ab sofort

TECHNISCHE KENNTNISSE

- Python
- PyTorch
- scikit-learn
- Vertex AI (GCP)
- NLP und LLMs
- Adversarial ML
- Explainable AI
- Threat Modelling
- LLM Red-Teaming
- Prompt Engineering

SPRACHEN

Englisch C1

Deutsch B1

Hindi, Muttersprache

INTERESSEN

Musik: Gesang, Synthesizer, Ukulele, Gitarre

Kochen: asiatische Küche, besonders indische

PROFIL

M.Sc.-Student der Künstlichen Intelligenz an der OTH Amberg-Weiden mit Schwerpunkt KI-Sicherheit, Red-Teaming von LLMs, Adversarial Machine Learning und belastbarer Evaluierung moderner KI-Systeme.

BERUFSERFAHRUNG

Research Analyst

01/2023 - 10/2024

GreyB Research, Chandigarh, Indien

- Entwickelte ein ML-System zur automatisierten Technologieklassifikation umfangreicher Patentkorpora.
- Führt Patent-Infringement-, Prior-Art- und Tech-Scouting-Analysen in KI/ML, Blockchain, 3GPP und IETF für internationale Kunden durch.

BILDUNGSWEG

M.Sc. Künstliche Intelligenz für industrielle Anwendungen

03/2025 - heute

OTH Amberg-Weiden, Bayern | Note 2,0

B.Tech in Information Technology

08/2019 - 06/2023

Institute of Engineering and Management, Kalkutta | Note 1,7 (8,6/10)

AUSGEWÄHLTE ARBEITEN

Ordnungsabhängige semantische Backdoor für Multi-Turn-LLMs

Qwen2.5-3B, LoRA, präregistrierte Evaluierung

- Erreichte 100% In-Distribution-ASR (n=140), 0% False-Trigger-Rate und 0,887 ASR auf ungesesehenen Paraphrasen.

Red Teaming AI Systems: A Practitioner's Guide

Portfolio-Wissensdatenbank, 2026

- Verfasste eine sechsstufige Methodik zum Testen von Chatbots, RAG-Pipelines und Agenten auf Basis von NIST AI RMF, OWASP und MITRE ATLAS.

Where the Devil Hides

Paper-Präsentation auf einer KI-Konferenz, 2026

- Präsentierte eine CVPR-2025-Studie zu passwortgesteuerten Backdoors in Trainingsdaten für Deepfake-Detektoren.

Multimodale Emotionserkennung

Springer-Buchkapitel, 2023

- Entwickelte ein Modell mit ca. 86% Genauigkeit und war Co-Autor einer Springer-Veröffentlichung aus dem Jahr 2023.